

[Título del Proyecto]**Fase 1 (P1) / Fase 2 (P2)****Grupo N° [XX]**

Integrantes:

Estudiante 1 (código) — Correo institucional

Estudiante 2 (código) — Correo institucional

Estudiante 3 (código) — Correo institucional

Enlace al Repositorio de Código: <https://github.com/usuario/repo-proyecto-rl>

Resumen

Resumen conciso (máximo 150 palabras) describiendo la tarea abordada, la formulación matemática del problema, el algoritmo de Reinforcement Learning implementado, la política de exploración utilizada y los resultados cuantitativos principales obtenidos (tasa de éxito, pasos promedio por episodio y retorno acumulado final).

1. Introducción y Descripción de la Tarea

Describir el problema y la tarea seleccionada dentro del entorno RoboCup 2D (Persecución, Conducción, Tiro al arco o Cooperación 2v1). Explicar la motivación, las dificultades asociadas a la simulación (ruido, dinámica física, control en tiempo real) y los objetivos específicos planteados para esta entrega.

2. Modelado Formal como MDP

Definir rigurosamente la tupla de Markov $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$:

- **Espacio de Estados ($\mathcal{S}$):** Detallar las variables observadas (distancias y ángulos polares). En Fase 1 (tabular), explicar y justificar el esquema de discretización utilizado y la cardinalidad total $|\mathcal{S}|$.
- **Espacio de Acciones ($\mathcal{A}$):** Detallar las macro-acciones definidas (potencias de DASH, ángulos de TURN, o KICK).
- **Función de Recompensa ($\mathcal{R}$):** Expresión matemática formal de la recompensa por paso $R(s, a, s')$. Justificar los valores asignados a estados terminales de éxito, penalizaciones temporales y recompensas intermedias (reward shaping).

- **Factor de Descuento (γ) y Horizonte:** Indicar el valor de $\gamma \in [0, 1)$ y el número máximo de pasos por episodio.

3. Algoritmo de Aprendizaje por Refuerzo

Describir el algoritmo implementado (ej. Monte Carlo Control On-Policy First-Visit, Q-Learning, SARSA para P1; o DQN / PPO para P2):

- Mecanismo de actualización de la función valor $Q(s, a)$ o gradiente de política.
- Política de exploración: Comparación entre ε -greedy fijo y ε -greedy con decaimiento ($\varepsilon_t = \max(\varepsilon_{min}, \varepsilon_0 \cdot d^t)$).
- Hiperparámetros de entrenamiento (tasa de aprendizaje α , tasa de exploración ε , número de episodios).

4. Resultados Experimentales y Análisis

Presentar el análisis cuantitativo y cualitativo del desempeño del agente:

1. **Curvas de Aprendizaje:** Gráfica del Retorno acumulado G_0 suavizado a lo largo de los episodios.
2. **Tasa de Éxito Temporal:** Porcentaje de episodios exitosos calculados en ventanas móviles de 20 o 50 episodios.
3. **Eficiencia:** Número de pasos requeridos por episodio para cumplir la meta.
4. **Visualización de la Política y Trayectorias:** Mapa de calor de la función valor $V(s) = \max_a Q(s, a)$ o visualización de las trayectorias 2D del agente en la cancha.

5. Discusión y Análisis

Discutir los hallazgos experimentales: ¿Qué impacto tuvo la discretización del estado? ¿Cómo afectó el decaimiento de exploración? ¿Se observó sobreajuste o políticas subóptimas? Identificar las principales limitaciones del enfoque tabular frente al espacio continuo.

6. Conclusiones

Sintetizar los logros principales de la entrega y plantear las mejoras o extensiones que se abordarán en la siguiente fase (Fase 2: Deep RL y desafío de partido / transferencia).

Referencias

- [1] Tiffany Tianhui Cai, Hongseok Namkoong, and Steve Yadlowsky. Diagnosing model performance under distribution shift. *arXiv preprint arXiv:2303.02011*, 2023.
- [2] Hiroaki Kitano, Minoru Asada, Yasuo Kuniyoshi, Itsuki Noda, and Eiichi Osawa. The robocup soccer server. In *RoboCup-97: Robot Soccer World Cup I*, pages 62–79. Springer, 1998.
- [3] Andrew Y. Ng, Daishi Harada, and Stuart Russell. Policy invariance under reward transformations: Theory and application to reward shaping. In *Proceedings of the Sixteenth International Conference on Machine Learning*, pages 278–287, 1999.
- [4] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2 edition, 2018.