

[Título del Proyecto: Tarea Restringida / Extensión]

Fase 1 (P1) / Fase 2 (P2)

Grupo N° [XX]

Integrantes:

Estudiante 1 (código) — Correo institucional

Estudiante 2 (código) — Correo institucional

Estudiante 3 (código) — Correo institucional

Enlace al Repositorio de Código: <https://github.com/usuario/repo-proyecto-rl>

Resumen

Resumen conciso (máximo 150 palabras) describiendo la tarea abordada, la formulación matemática del problema, el algoritmo de Reinforcement Learning implementado, la política de exploración utilizada y los resultados cuantitativos principales obtenidos (tasa de éxito, pasos promedio por episodio y retorno acumulado final).

1. Introducción y Descripción de la Tarea

Describir el problema y la tarea seleccionada dentro del entorno RoboCup 2D (Persecución, Conducción, Tiro al arco o Cooperación 2v1). Explicar la motivación, las dificultades asociadas a la simulación (ruido, dinámica física, control en tiempo real) y los objetivos específicos planteados para esta entrega.

2. Modelado Formal como MDP

Definir rigurosamente la tupla de Markov $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$:

- **Espacio de Estados ($\mathcal{S}$):** Detallar las variables observadas (distancias y ángulos polares). En Fase 1 (tabular), explicar y justificar el esquema de discretización utilizado y la cardinalidad total $|\mathcal{S}|$.
- **Espacio de Acciones ($\mathcal{A}$):** Detallar las macro-acciones definidas (potencias de DASH, ángulos de TURN, o KICK).
- **Función de Recompensa ($\mathcal{R}$):** Expresión matemática formal de la recompensa por paso $R(s, a, s')$. Justificar los valores asignados a estados terminales de éxito, penalizaciones temporales y recompensas intermedias (reward shaping).

- **Factor de Descuento (γ) y Horizonte:** Indicar el valor de $\gamma \in [0, 1)$ y el número máximo de pasos por episodio.

3. Algoritmo de Aprendizaje por Refuerzo

Describir el algoritmo implementado (ej. Monte Carlo Control On-Policy First-Visit, Q-Learning, SARSA para P1; o DQN / PPO para P2):

- Mecanismo de actualización de la función valor $Q(s, a)$ o gradiente de política.
- Política de exploración: Comparación entre ε -greedy fijo y ε -greedy con decaimiento ($\varepsilon_t = \max(\varepsilon_{min}, \varepsilon_0 \cdot d^t)$).
- Hiperparámetros de entrenamiento (tasa de aprendizaje α , tasa de exploración ε , número de episodios).

4. Resultados Experimentales y Análisis

Presentar el análisis cuantitativo y cualitativo del desempeño del agente:

1. **Curvas de Aprendizaje:** Gráfica del Retorno acumulado G_0 suavizado a lo largo de los episodios.
2. **Tasa de Éxito Temporal:** Porcentaje de episodios exitosos calculados en ventanas móviles de 20 o 50 episodios.
3. **Eficiencia:** Número de pasos requeridos por episodio para cumplir la meta.
4. **Visualización de la Política y Trayectorias:** Mapa de calor de la función valor $V(s) = \max_a Q(s, a)$ o visualización de las trayectorias 2D del agente en la cancha.

5. Discusión y Análisis de Ablación

Discutir los hallazgos experimentales: ¿Qué impacto tuvo la discretización del estado? ¿Cómo afectó el decaimiento de exploración? ¿Se observó sobreajuste o políticas subóptimas? Identificar las principales limitaciones del enfoque tabular frente al espacio continuo.

6. Conclusiones

Sintetizar los logros principales de la entrega y plantear las mejoras o extensiones que se abordarán en la siguiente fase (Fase 2: Deep RL y desafío de partido / transferencia).

Referencias

- [1] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.
- [2] H. Kitano et al., “The RoboCup Soccer Server,” in *RoboCup-97: Robot Soccer World Cup I*, Springer, 1998, pp. 62–79.
- [3] A. Y. Ng, D. Harada, and S. Russell, “Policy invariance under reward transformations: Theory and application to reward shaping,” in *ICML*, 1999, pp. 278–287.